

Priebežná správa o riešení DP2

|||||

Vibrodiagnostika strojov s priemyselným internetom vecí

|||||

Bc. Miroslav Hájek

Vedúci práce: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

Konzultant: Ing. Lukáš Doubravský

Motivácia problému

- **Problémy strojárov**


- Kontinuálne monitorovanie a prediktívna údržba
- Predĺžiť životnosť súčiastok a predchádzať zlyhaniu strojov

- **Výskumné otázky**

- Aké atribúty dokážeme extrahovať z vibračných signálov?
- Akú úsporu dát dosiahneme výberom atribútov?
- Aké budú presnosti diagnostiky porúch s rôznymi sadami atribútov?
- Ako môžeme priebežne označovať poruchové stavy?

MaFaulDa dataset

- **1951 záznamov** o dĺžke 5 sekúnd (s 50 kHz)
- Rýchlosti rotácie: 737 – 3686 rpm
- Dve ložiská: vnútorné (A) a vonkajšie (B)
- **Signály:**
 - tachometer (impulzy otáčok)
 - 2x piezoelektrický akcelerometer (x, y, z)
 - mikrofón
- **Simulované poruchové stavy (6 tried)** s rôznou závažnosťou:
 - bez poruchy, nevyváženosť, nesúosovosť,
 - valivé ložiská: vnútorné/vonkajšie krúžky, gulôčky



Extrakcia atribútov zo signálov

- **Časové atribúty (10):**

- smerodajná odchýlka, šikmosť, špicatosť, rms (*kvadratický priemer*),
špička-špička, maximum, crest, margin, impulse, shape

- **Spektrálne atribúty (11):**

- centroid, energia, entropia, negentropia, smerodajná odchýlka, šikmosť,
špicatosť, roll-on, roll-off, SNR (*signal-to-noise*), korelácia spektier

- **Ďalšie:** harmonické zložky, WPD (*wavelet packet*) koeficienty, ...



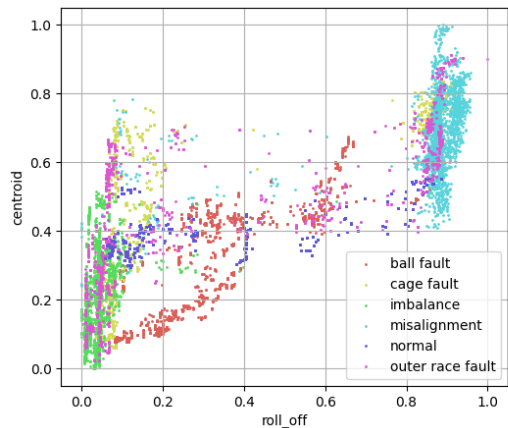
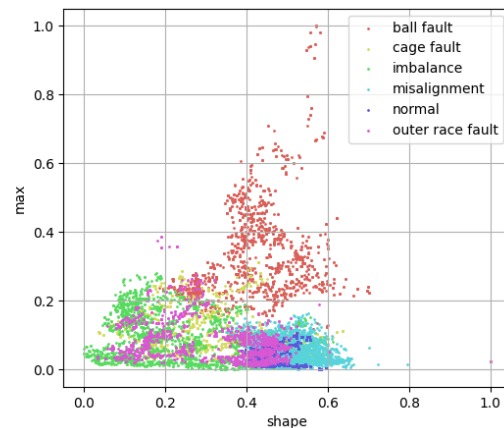
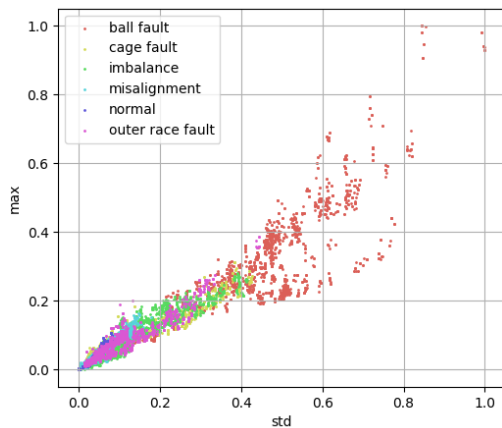

- **Stratový kompresný pomer:**

- 2380:1, pre 6 atribútov až 16600:1
- z 31.54 Gs/rok na 1.89 Ms/rok (*Gs = gigasamples, Ms - megasamples*)

Techniky výberu atribútov

- **Učenie s učiteľom:**
 - Korelačný koeficient (*Point-biserial*)
 - ANOVA F štatistika
 - Vzájomná informácia (*Mutual information*)
- **Ensemble metóda:**
 - Súčin poradí (*Rank product*)
- **Učenie bez učiteľa:**
 - Analýza hlavných komponentov (*PCA*)
- Výber v dávkovom a inkrementálnom učení

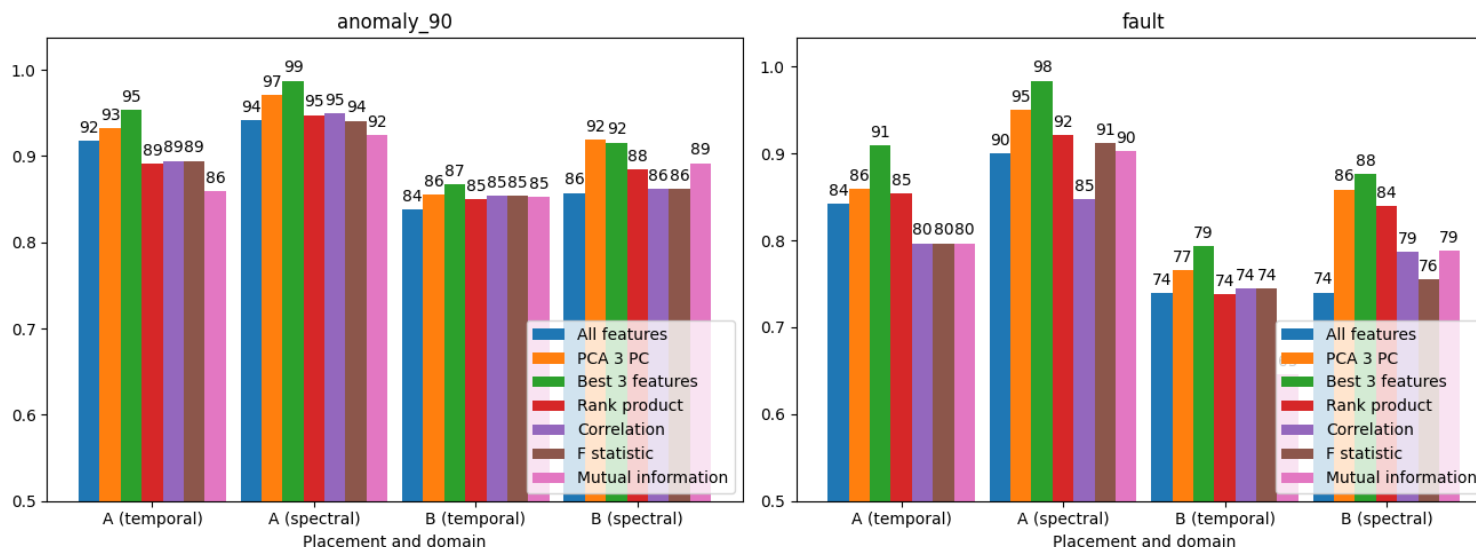
Techniky výberu atribútov



Trojice atribútov zistené súčinom poradí na vnútornom ložisku

Diagnostika porúch s KNN modelom



- **K-najbližích susedov (KNN)** zo všetkých atribútov pre každú doménu
- Trojica atribútov s najlepšou presnosťou (exhaustívne)
- Trojica atribútov podľa 4 rôznych metód na výber atribútov



Presnosti KNN na validačnej sade (20%) voči cieľovým premenným

Inkrementálne učenie

- **Scenár** s KNN a normalizovanými atribútmi:
 - Oneskorené anotovanie (2 typy posuvného okna)
 - Vynechávanie anotácií
- Porovnanie voči presnosti dávkového učenia s vyváženým datasetom



Prieskumné merania a spolupráce

Neformálni partneri:



SLOVENSKÁ TECHNICKÁ
UNIVERZITA V BRATISLAVE
STROJNÍCKA FAKULTA



• **Stroje na meranie:**

- Ventilátor (1 ks)
- Špirálový kompresor (2 ks)
- Čerpadlo na pitnú vodu (3 ks)
s elektromotorom (3 ks)



• **Plán meraní:**

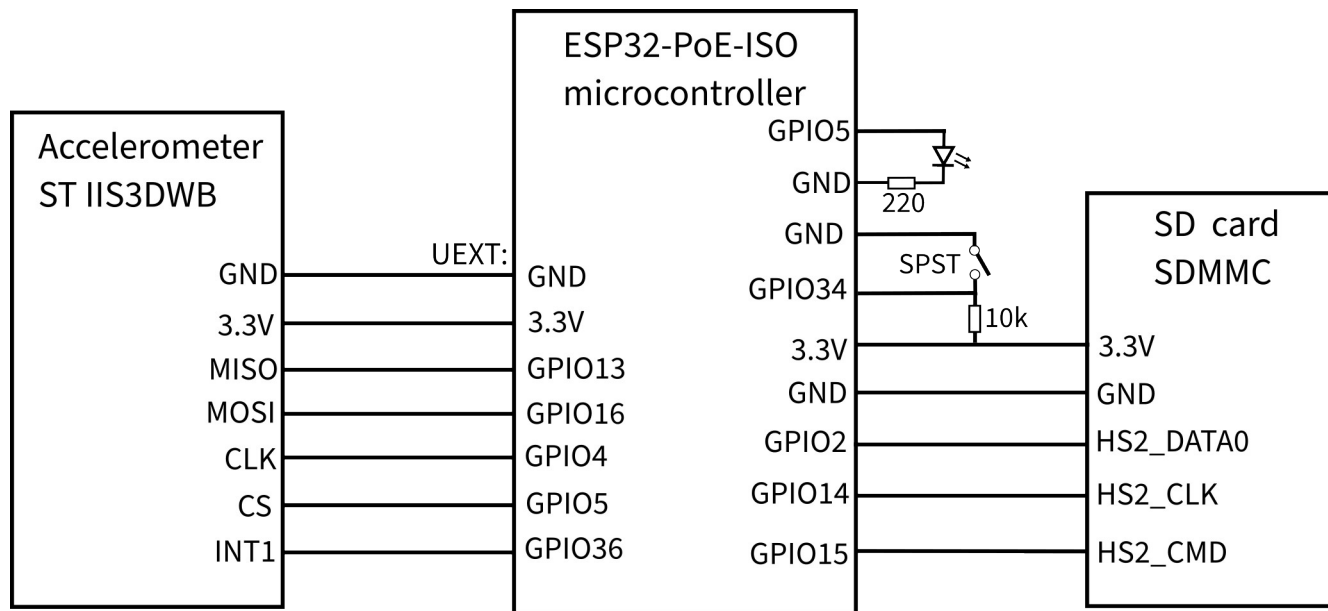
- Na ložiskách každé 2 týždne
- Dataset z BVS cloudu



Návrh meracieho zariadenia

• Lepší akcelerometer:

- Šírka pásma: 6.3 kHz, ODR (Output data rate): 26.7 kHz,
- Rozsah: 2 – 16 g, Zbernica: SPI, 16-bit, Šum: $75 \mu\text{g}/\sqrt{\text{Hz}}$



Úlohy na dokončenie v DP3

1. Zpracovanie pripomienok z obhajoby
2. Implementácia firmvéru
3. Zber dát zo strojov a ich anotovanie
4. Prepojenie výberu atribútov s
inkrementálnym učením
5. Ladenie hyperparametrov na dosiahnutie
lepších metrík klasifikácie

